实验四

spark安装

- 首先从http://spark.apache.org/downloads.html下载了3.5.3的spark
- 解压spark文件

```
cd /usr/local #我是讲spark放在了这个文件下
sudo tar -xzvf spark-3.5.3-bin-hadoop3.tgz
sudo mv spark-3.3.0-bin-hadoop3 spark
```

- 设置环境变量

```
nano ~/.bashrc
export SPARK_HOME=/usr/local/spark
export PATH=$PATH:$SPARK_HOME/bin:$SPARK_HOME/sbin
source ~/.bashrc
```

- 配置Spark以确保其能与Hadoop集成

```
sudo cp $SPARK_HOME/conf/spark-env.sh.template $SPARK_HOME/conf/spark-env.sh
sudo cp $SPARK_HOME/conf/spark-defaults.conf.template $SPARK_HOME/conf/spark-defaults.conf
```

编辑`spark-env.sh`，添加Hadoop配置目录和Spark master主机地址：

```
sudo nano $SPARK_HOME/conf/spark-env.sh
export HADOOP_CONF_DIR=$HADOOP_HOME/etc/hadoop
export SPARK_MASTER_HOST=localhost
```

- 启动Spark的Master和一个Worker：

```
start-master.sh
start-worker.sh spark://localhost:7077
```

- 在浏览器中访问`http://localhost:8080`，查看Spark Master的Web界面以确认Spark集群状态。

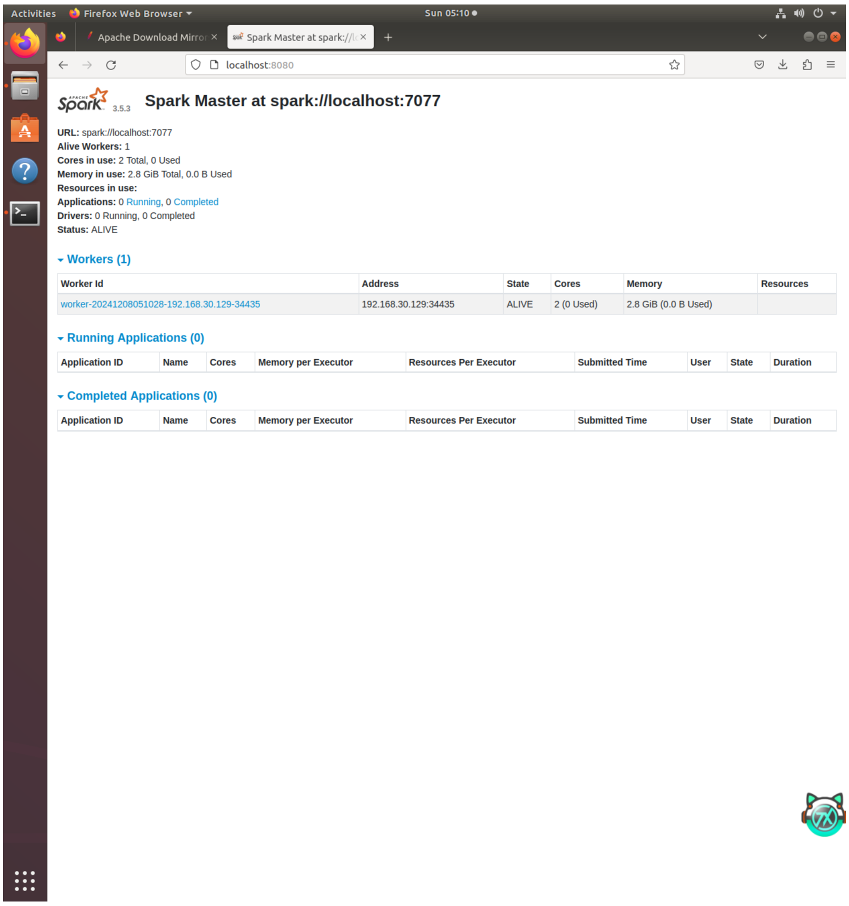

- 运行一个测试作业，如计算π的值，验证安装：

```
$SPARK_HOME/bin/run-example SparkPi 10
```

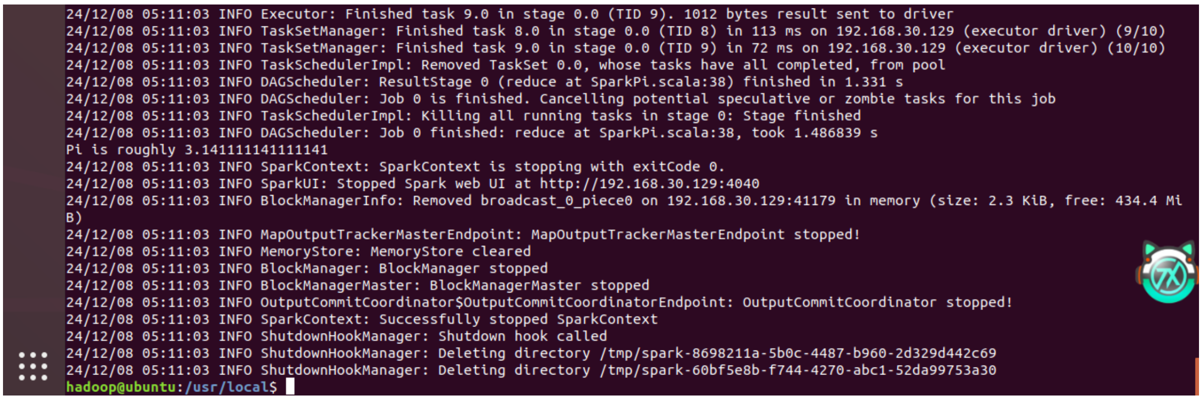

可以看到成功计算出结果，成功启动。

任务1：Spark RDD编程

1、查询特定日期的资金流入和流出情况： 使用 user_balance_table ，计算出所有用户在每一天的总资金流入和总资金流出量。

```
#创建一个新目录来存放数据和代码
mkdir /usr/local/spark_work
mv ~/Downloads/user_balance_table.csv /usr/local/spark_work/
```

在`/usr/local/spark_work`目录中，创建一个新的Python脚本文件

```
cd /usr/local/spark_work
sudo nano /usr/local/spark_work/user_balance_analysis.py
```

使用`spark-submit`命令来运行Spark脚本：

```
spark-submit user_balance_analysis.py
```

代码：

```
from pyspark import SparkContext, SparkConf

def parse_line(line):
    fields = line.split(',')
    try:
        report_date = fields[1]
        total_purchase_amt = int(fields[4])
        total_redeem_amt = int(fields[8])
        return (report_date, total_purchase_amt, total_redeem_amt)
    except ValueError:
        return None

def main():
    conf = SparkConf().setAppName("User Balance Analysis")
    sc = SparkContext(conf=conf)
    lines =
sc.textFile("hdfs://localhost:9000/user/hadoop/user_balance_table.csv")
    parsed_rdd = lines.map(parse_line).filter(lambda x: x is not None)
    daily_totals = parsed_rdd.map(lambda x: (x[0], (x[1], x[2])))\
                             .reduceByKey(lambda a, b: (a[0] + b[0], a[1] +
b[1]))


    results = daily_totals.map(lambda x: f"{x[0]} {x[1][0]} {x[1][1]}")
    for result in results.collect():
        print(result)

    sc.stop()

if __name__ == "__main__":
    main()
```

- 使用 `parse_line` 函数解析每一行数据，提取 `report_date`（报告日期），`total_purchase_amt`（总购买金额），和 `total_redeem_amt`（总赎回金额）。如果转换过程中出现错误（例如数据格式不正确），该行数据将被过滤掉。
- 将解析后的数据映射成键值对形式，键是 `report_date`，值是一个包含 `total_purchase_amt` 和 `total_redeem_amt` 的元组。
- 使用 `reduceByKey` 方法对同一天的数据进行聚合，计算每天的总购买和总赎回金额。

运行结果：

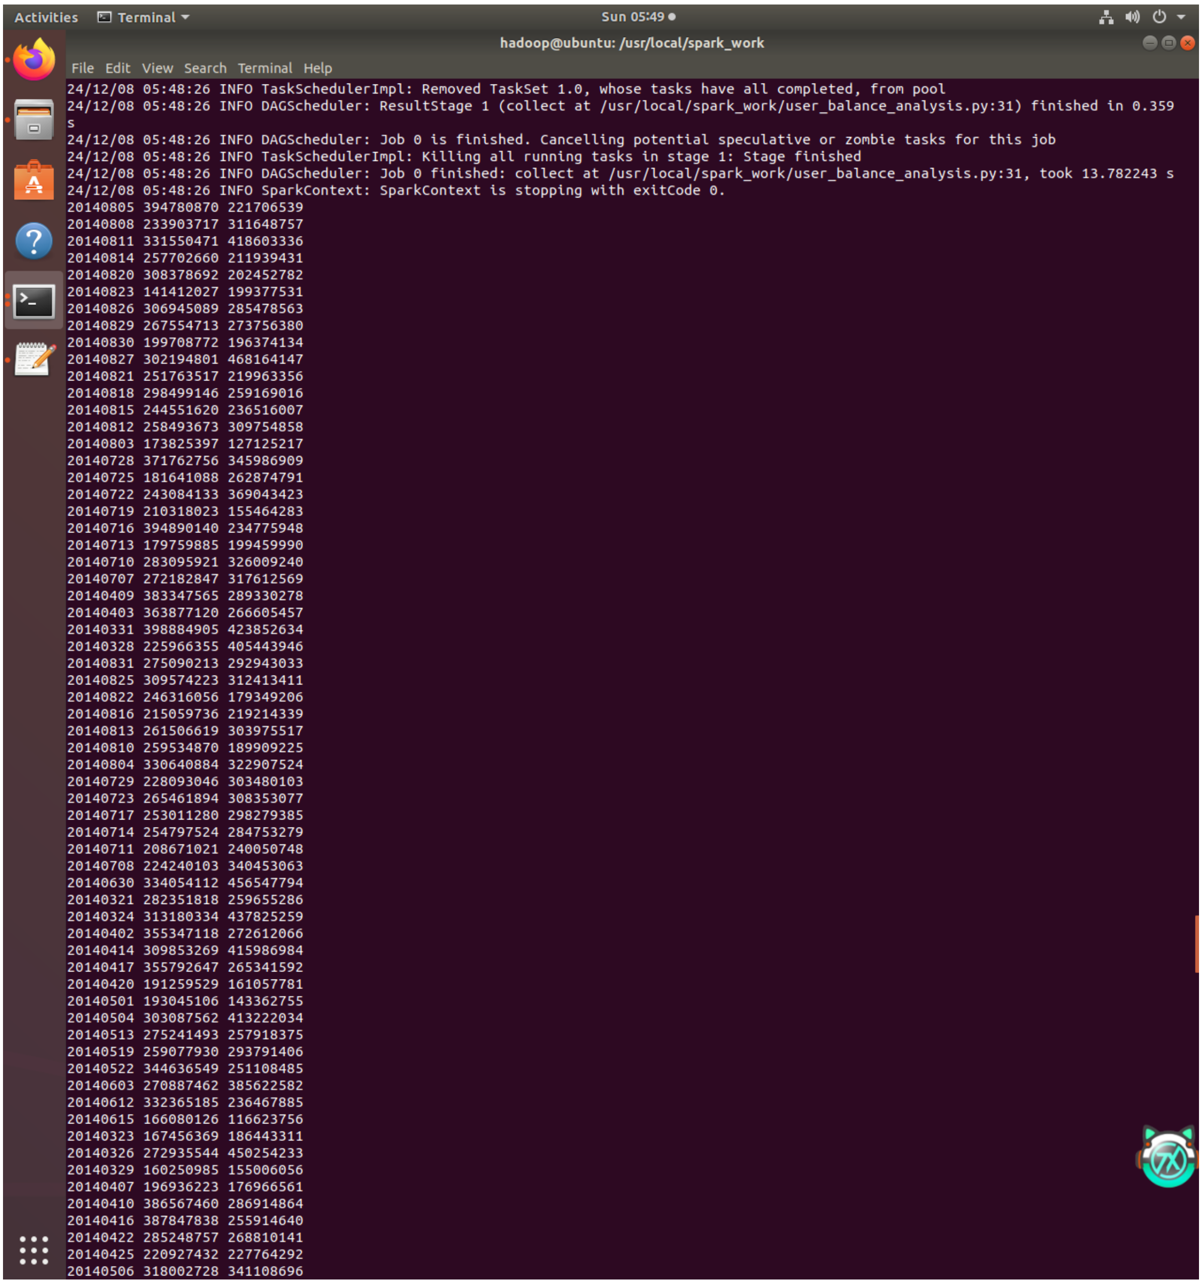

2. **活跃用户分析： 使用 user_balance_table， 定义活跃用户为在指定月份内有至少五天记录的用户，统计2014年8月的活跃用户总数。**

代码：

```
from pyspark import SparkContext, SparkConf

def parse_line(line):
    fields = line.split(',')
    try:
        user_id = fields[0]
        report_date = fields[1]
        if '201408' in report_date:
            return (user_id, report_date)
    except IndexError:
        return None
    return None

def main():
    conf = SparkConf().setAppName("Active User Analysis")
    sc = SparkContext(conf=conf)
```

```python
    lines =
sc.textFile("hdfs://localhost:9000/user/hadoop/user_balance_table.csv")

    user_dates = lines.map(parse_line).filter(lambda x: x is not None)
    user_unique_dates = user_dates.distinct().map(lambda x: (x[0], {x[1]}))
    user_aggregated_dates = user_unique_dates.reduceByKey(lambda a, b:
a.union(b))
    active_users = user_aggregated_dates.filter(lambda x: len(x[1]) >= 5)
    active_user_count = active_users.count()
    print(f"Active users total: {active_user_count}")

    sc.stop()

if __name__ == "__main__":
    main()
```

- `parse_line(line)` 函数尝试解析文本，将其分割为字段，并检查日期字段是否包含"201408"。如果是，它返回一个元组，包含用户ID和报告日期。如果行不能正确解析或日期不匹配，函数返回 `None`。
- `filter(lambda x: x is not None)` 移除所有 `None` 值，这些通常是解析失败或日期不符的行。
- `distinct()` 去除重复的 (user_id, report_date) 对。
- `map(lambda x: (x[0], {x[1]}))` 转换为键值对，其中键是 `user_id`，值是包含一个日期的集合。

运行结果：

```
s
24/12/08 05:51:38 INFO DAGScheduler: Job 0 is finished. Cancelling potential speculative or zombie tasks for this job
24/12/08 05:51:38 INFO TaskSchedulerImpl: Removed TaskSet 2.0, whose tasks have all completed, from pool
24/12/08 05:51:38 INFO TaskSchedulerImpl: Killing all running tasks in stage 2: Stage finished
24/12/08 05:51:38 INFO DAGScheduler: Job 0 finished: count at /usr/local/spark_work/user_balance_analysis_2.py:36, took 17.420267 s
Active users total: 12767
24/12/08 05:51:38 INFO SparkContext: SparkContext is stopping with exitCode 0.
24/12/08 05:51:38 INFO SparkUI: Stopped Spark web UI at http://192.168.30.129:4040
24/12/08 05:51:38 INFO MapOutputTrackerMasterEndpoint: MapOutputTrackerMasterEndpoint stopped!
24/12/08 05:51:39 INFO MemoryStore: MemoryStore cleared
```

任务2：Spark SQL编程

1、按城市统计2014年3月1日的平均余额：计算每个城市在2014年3月1日的用户平均余额(tBalance)，按平均余额降序排列。

代码：

```python
from pyspark.sql import SparkSession

def main():
    spark = SparkSession.builder.appName("Average Balance by City").getOrCreate()

    user_profile_df =
spark.read.csv("hdfs://localhost:9000/user/hadoop/user_profile_table.csv",
header=True, inferSchema=True)
    user_balance_df =
spark.read.csv("hdfs://localhost:9000/user/hadoop/user_balance_table.csv",
header=True, inferSchema=True)
    #将DataFrame注册为临时SQL视图，允许我们像操作SQL数据库表一样操作这些DataFrame。
    user_profile_df.createOrReplaceTempView("user_profiles")
```

```
    user_balance_df.createOrReplaceTempView("user_balances")


    result = spark.sql("""
        SELECT p.city, AVG(b.tBalance) AS avg_balance
        FROM user_profiles p
        JOIN user_balances b ON p.user_id = b.user_id
        WHERE b.report_date = '20140301'
        GROUP BY p.city
        ORDER BY avg_balance DESC
    """)


    result.show()

    spark.stop()

if __name__ == "__main__":
    main()
```

代码解释:

- 使用`JOIN`将`user_profiles`和`user_balances`表通过`user_id`字段联接。
- 通过`WHERE`语句筛选`report_date`为2014年3月1日的记录。
- 按`city`分组，并计算每个城市的平均余额`AVG(b.tBalance)`。
- 结果按平均余额降序排列。

运行结果:

```
+-------+------------------+
|   city|       avg_balance|
+-------+------------------+
|6281949| 2795923.837298216|
|6301949|2650775.0664451825|
|6081949|2643912.7566638007|
|6481949|2087617.2136986302|
|6411949|1929838.5617977527|
|6412149| 1896363.471625767|
|6581949|1526555.5551020408|
+-------+------------------+
```

2、统计每个城市总流量前3高的用户：统计每个城市中每个用户在2014年8月的总流量（定义为total_purchase_amt + total_redeem_amt），并输出每个城市总流量排名前三的用户ID及其总流量。

代码:

```
from pyspark.sql import SparkSession
from pyspark.sql.functions import col, sum
from pyspark.sql.window import Window
from pyspark.sql.functions import rank

def main():
    spark = SparkSession.builder.appName("Top 3 Users by City").getOrCreate()
```

```
    user_profile_df =
spark.read.csv("hdfs://localhost:9000/user/hadoop/user_profile_table.csv",
header=True, inferSchema=True)
    user_balance_df =
spark.read.csv("hdfs://localhost:9000/user/hadoop/user_balance_table.csv",
header=True, inferSchema=True)

    user_profile_df.createOrReplaceTempView("user_profiles")
    user_balance_df.createOrReplaceTempView("user_balances")

    # SQL查询计算每个用户在2014年8月的总流量
    spark.sql("""
        SELECT p.city, b.user_id,
               (SUM(b.total_purchase_amt) + SUM(b.total_redeem_amt)) AS
total_traffic
        FROM user_profiles p
        JOIN user_balances b ON p.user_id = b.user_id
        WHERE b.report_date BETWEEN '20140801' AND '20140831'
        GROUP BY p.city, b.user_id
    """).createOrReplaceTempView("city_user_traffic")

    # 使用窗口函数按城市分组对用户总流量进行排序，并获取每个城市的前三名用户
    windowSpec = Window.partitionBy("city").orderBy(col("total_traffic").desc())
    top_users_by_city = spark.sql("""
        SELECT city, user_id, total_traffic, RANK() OVER (PARTITION BY city ORDER
BY total_traffic DESC) as rank
        FROM city_user_traffic
    """).filter("rank <= 3")

    # 显示结果
    top_users_by_city.show()

    spark.stop()

if __name__ == "__main__":
    main()
```

代码解释:

- 使用`Window.partitionBy("city").orderBy(col("total_traffic").desc())`定义了一个按城市分组，根据总流量降序排序的窗口。
- 在查询中，对每个城市的用户总流量使用了`rank()`函数进行排名，并通过过滤条件选择排名前三的记录。
- 首先联结用户档案表和余额表，过滤出2014年8月的数据，计算总流量。

运行结果:

city	user_id	total_traffic	rank
6081949	27235	108475680	1
6081949	27746	76065458	2
6081949	18945	55304049	3
6281949	15118	149311909	1
6281949	11397	124293438	2
6281949	25814	104428054	3
6301949	2429	109171121	1
6301949	26825	95374030	2
6301949	10932	74016744	3
6411949	662	75162566	1
6411949	21030	49933641	2
6411949	16769	49383506	3
6412149	22585	200516731	1
6412149	14472	138262790	2
6412149	25147	70594902	3
6481949	12026	51161825	1
6481949	670	49626204	2
6481949	14877	34488733	3
6581949	9494	38854436	1
6581949	26876	23449539	2

only showing top 20 rows

任务3：Spark ML编程

```
from pyspark import SparkContext, SparkConf
from pyspark.sql import SparkSession, functions as F
from pyspark.sql.types import IntegerType, DateType, StructType, StructField,
DoubleType
from pyspark.ml.feature import VectorAssembler
from pyspark.ml.regression import LinearRegression
from pyspark.ml.evaluation import RegressionEvaluator
from datetime import datetime, timedelta

def main():
    conf = SparkConf().setAppName("Finance Purchase and Redeem Prediction")
    sc = SparkContext(conf=conf)
    spark = SparkSession(sc)

    data_path = "hdfs://localhost:9000/user/hadoop/user_balance_table.csv"
    lines = sc.textFile(data_path)
    def parse_line(line):
        fields = line.split(',')
        try:
            report_date = int(fields[1])
            total_purchase_amt = float(fields[8])
            total_redeem_amt = float(fields[13])
            return (report_date, total_purchase_amt, total_redeem_amt)
        except:
            return None

    transactions = lines.map(parse_line).filter(lambda x: x is not None)

    schema = StructType([
        StructField("report_date", IntegerType(), True),
        StructField("total_purchase_amt", DoubleType(), True),
        StructField("total_redeem_amt", DoubleType(), True)
    ])
    df = spark.createDataFrame(transactions, schema)

    vectorAssembler = VectorAssembler(inputCols=["report_date"],
outputCol="features")
    df_vector = vectorAssembler.transform(df)

    train_data, test_data = df_vector.randomSplit([0.8, 0.2], seed=42)
```

```
    lr_purchase = LinearRegression(featuresCol='features',
labelCol='total_purchase_amt')
    lr_redeem = LinearRegression(featuresCol='features',
labelCol='total_redeem_amt')

    model_purchase = lr_purchase.fit(train_data)
    model_redeem = lr_redeem.fit(train_data)

    date_range = [datetime(2014, 9, 1) + timedelta(days=x) for x in range(30)]
    predict_df = spark.createDataFrame([(int(d.strftime('%Y%m%d')),) for d in
date_range], ["report_date"])
    predict_features = vectorAssembler.transform(predict_df)

    predictions_purchase = model_purchase.transform(predict_features)
    predictions_redeem = model_redeem.transform(predict_features)

    predictions = predictions_purchase.select("report_date",
F.col("prediction").alias("purchase")).join(
        predictions_redeem.select("report_date",
F.col("prediction").alias("redeem")), "report_date"
    )
predictions.write.csv("hdfs://localhost:9000/user/hadoop/tc_comp_predict_table.cs
v", header=True)

    # Stop the Spark context
    sc.stop()

if __name__ == "__main__":
    main()
```

- 将数据随机分为训练集和测试集（80% 训练，20% 测试）。
- 分别为申购量和赎回量初始化线性回归模型，特征列为 `features`，标签列分别为 `total_purchase_amt` 和 `total_redeem_amt`。

结果：

A	B	C
20140901	3.618E+09	345236642
20140902	362454259	346054154
20140903	363131475	346871463
20140904	363808795	347689033
20140905	364486088	348506460
20140906	365163323	349323894
20140907	365840662	350141343
20140908	366517883	350958849
20140909	367195234	351776305
20140910	367872383	352593795
20140911	368549592	353411141
20140912	369227045	354228640
20140913	369904187	355046133
20140914	370581469	355863576
20140915	371258667	356681103
20140916	371935973	357498569
20140917	372613375	358316052
20140918	373290646	359133519
20140919	373967757	359950803
20140920	374645187	360768444
20140921	375322469	361585770
20140922	375999710	362403239
20140923	376676842	363220788
20140924	377354286	364038267
20140925	378031487	364855696
20140926	378708797	365673158
20140927	379385931	366490590
20140928	380063342	367307941
20140929	380740660	368125421
20140930	381417878	368943022

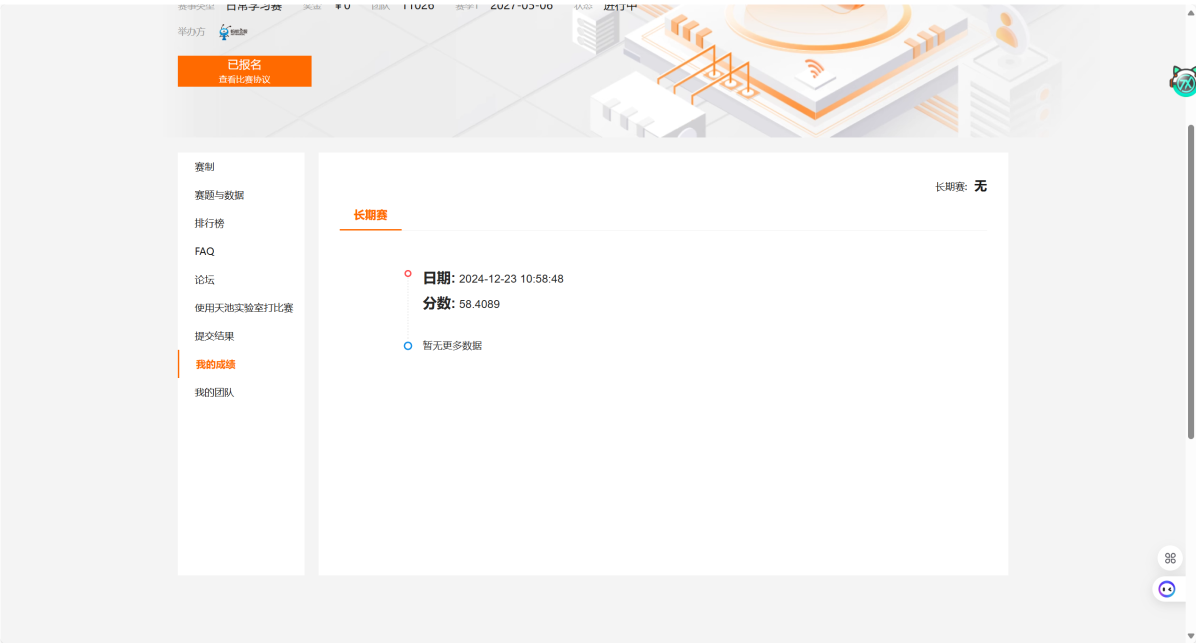

效果比较一般，感觉有以下的问题：

1. 线性模型拟合效果较差

2. 在划分测试集和训练集可能比例不是很恰当

遇到的问题：

1. 读取文件

Spark 尝试从 HDFS 读取数据文件 `user_balance_table.csv`，但没有在指定的路径找到该文件：

```
org.apache.hadoop.mapred.InvalidInputException: Input path does not exist:
hdfs://localhost:9000/usr/local/spark_work/user_balance_table.csv
```

所以需要将文件上传到HDFS,具体操作同实验一。